Báo cáo AI
Student Performance Prediction
Nhóm 8

1. Giới thiệu **2**
1.1 Mô tả bài toán 2
1.2 Bối cảnh thực tế 2
1.3 Mục tiêu 2
1.4 Lựa chọn model và metric 2
2. Phương pháp **3**
2.1 Mô tả Dataset 3
2.2 Tiền xử lý dữ liệu 3
2.3 Lựa chọn model 4
2.4 References 4
3. Kết quả **5**
3.1 Bảng so sánh models 5
3.2 Biểu đồ đánh giá 6
3.3 Model được chọn 7
4. Ứng dụng thực tế **7**
4.1 Use Case Scenario 1 7
4.2 Use Case Scenario 2 8
4.3 Hạn chế khi triển khai 8
4.4 Demo 8
5. Kết luận **9**
5.1 Tóm tắt 9
5.2 Hạn chế 9
5.3 Hướng phát triển 9

1. Giới thiệu

1.1 Mô tả bài toán

Trong môi trường giáo dục hiện đại, việc dự đoán hiệu suất học tập qua bằng điểm cuối kỳ của học có ý nghĩa quan trọng trong việc:

- Phát hiện sớm sinh viên có nguy cơ học kém
- Hỗ trợ giảng viên/cố vấn đưa ra can thiệp kịp thời
- Tối ưu hóa chiến lược học tập cá nhân hóa

Bài toán dự đoán một giá trị liên tục (điểm cuối kỳ) là bài toán hồi quy

1.2 Bối cảnh thực tế

Trường THPT muốn dự đoán điêm cuối kỳ dựa trên:

- attendance (Số buổi học)
- study hours (Số giờ học)
- previous scores (Điểm kỳ trước)
- failure (Số môn rớt)

1.3 Mục tiêu

- Xây dựng mô hình dự đoán điểm số sinh viên
- So sánh nhiều thuật toán Regression
- Chọn mô hình tốt nhất dựa trên metrics
- Triển khai demo ứng dụng thực tế

1.4 Lựa chọn model và metric

Model được chọn: Random Forest, Gradient Boosting, Linear Regression

Từ các model trên sẽ so sánh với nhau bằng metric như: MAE, RMSE, R2SCORE để chọn model tốt nhất

2. Phương pháp

2.1 Mô tả Dataset

Dataset Student Performance từ UCI Machine Learning Repository
Các feature quan trọng:

- studytime (Thời gian học)
- failures (Số lần trượt trước đó)
- absences (số buổi nghỉ học)
- Medu, Fedu (Nghề nghiệp cha mẹ
- G1, G2, G3 (Điểm số kỳ 1, 2, 3)
- higher (có muốn học đại học không)

2.2 Tiền xử lý dữ liệu

Các bước tiền xử lý dữ liệu:

- Missing values handling:
  a) Với dữ liệu số: Sử dụng giá trị trung bình - Giữ lại dữ liệu thay vì xóa dòng, Mean phù hợp với dữ liệu số phân bố tương đối ổn định
  b) Với dữ liệu phân loại: Sử dụng giá trị xuất hiện nhiều nhất - Điền bằng giá trị phổ biến nhất giúp bảo toàn phân bố dữ liệu
- Feature Scaling :Áp dụng StandardScaler - Đưa các đặc trưng số về cùng thang đo, Tránh đặc trưng lớn lấn át đặc trưng nhỏ, Góp phần làm model học tốt hơn
- Encoding: Áp dụng One-Hot Encoding cho dữ liệu dạng category/string/bool - Chuyển dữ liệu dạng chữ thành dạng số để mô hình xử lý
- Feature Selection: Nhóm chọn các đặc trưng quan trọng nhất để huấn luyện mô hình - Giảm nhiễu từ các đặc trưng ít liên quan, Tăng tốc độ huấn luyện , Hạn chế overfitting
- Outlier Handling: Biến absences (số buổi nghỉ học) có một số giá trị quá lớn có thể gây nhiễu cho mô hình. Nhóm áp dụng kỹ thuật cắt ngưỡng (clipping): absences = absences.clip(upper=20) - Giảm ảnh hưởng của các giá trị ngoại lệ
- Chia tập dữ liệu: Dữ liệu được chia: 80% Training set , 20% Testing set - Huấn luyện mô hình trên tập train, Đánh giá khách quan trên tập test

2.3 Lựa chọn model

Trong bài toán dự đoán điểm số sinh viên, nhóm sử dụng và so sánh nhiều mô hình hồi quy khác nhau nhằm tìm ra mô hình phù hợp nhất.

1. Linear Regression: là mô hình hồi quy tuyến tính, giả định rằng biến mục tiêu có mối quan hệ tuyến tính với các đặc trưng đầu vào.
   Ưu điểm:
   - Đơn giản, dễ triển khai.
   - Dễ giải thích mức ảnh hưởng của từng đặc trưng.
   Nhược điểm:
   - Không mô hình hóa tốt các quan hệ phi tuyến.

2. Random Forest Regressor: là phương pháp Ensemble Learning, kết hợp nhiều Decision Tree để tăng độ chính xác.
   Nguyên lý:
   - Chọn đặc trưng tốt nhất để chia dữ liệu.
   - Tối thiểu hóa Mean Squared Error (MSE).
   Ưu điểm:
   - Giảm overfitting.
   - Ổn định hơn Decision Tree.
   Nhược điểm:
   - Khó giải thích hơn Linear Regression.
3. Gradient Boosting Regressor: xây dựng nhiều mô hình yếu tuần tự, trong đó mỗi mô hình mới học từ sai số của mô hình trước
   Nguyên lý:
   - Tối ưu hàm mất mát bằng Gradient Descent.
   - Giảm lỗi dần qua từng vòng boosting.

   Ưu điểm:
   - Hiệu suất cao trên dữ liệu dạng bảng.
   - Thường cho kết quả tốt nhất.

   Nhược điểm:
   - Thời gian huấn luyện lâu hơn.
   - Cần tuning hyperparameter.

2.4 References

[1] Aurélien Géron, Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow, O'Reilly Media, 2019.

[2] Christopher M. Bishop, Pattern Recognition and Machine Learning, Springer, 2006.

[3] Trevor Hastie, Robert Tibshirani, Jerome Friedman, The Elements of Statistical Learning, Springer, 2009.

[4] Scikit-learn Documentation:
https://scikit-learn.org/

[5] XGBoost Documentation:
https://xgboost.readthedocs.io/

3. Kết quả

3.1 Bảng so sánh models

	Model	CV R2	Test R2	RMSE	MAE
1	Random Forest	0.7051	0.8292	1.8716	1.4216
2	Gradient Boosting	0.6896	0.7785	2.1312	1.5355
0	Linear Regression	0.6745	0.7177	2.4061	1.9750

3.2 Biểu đồ đánh giá

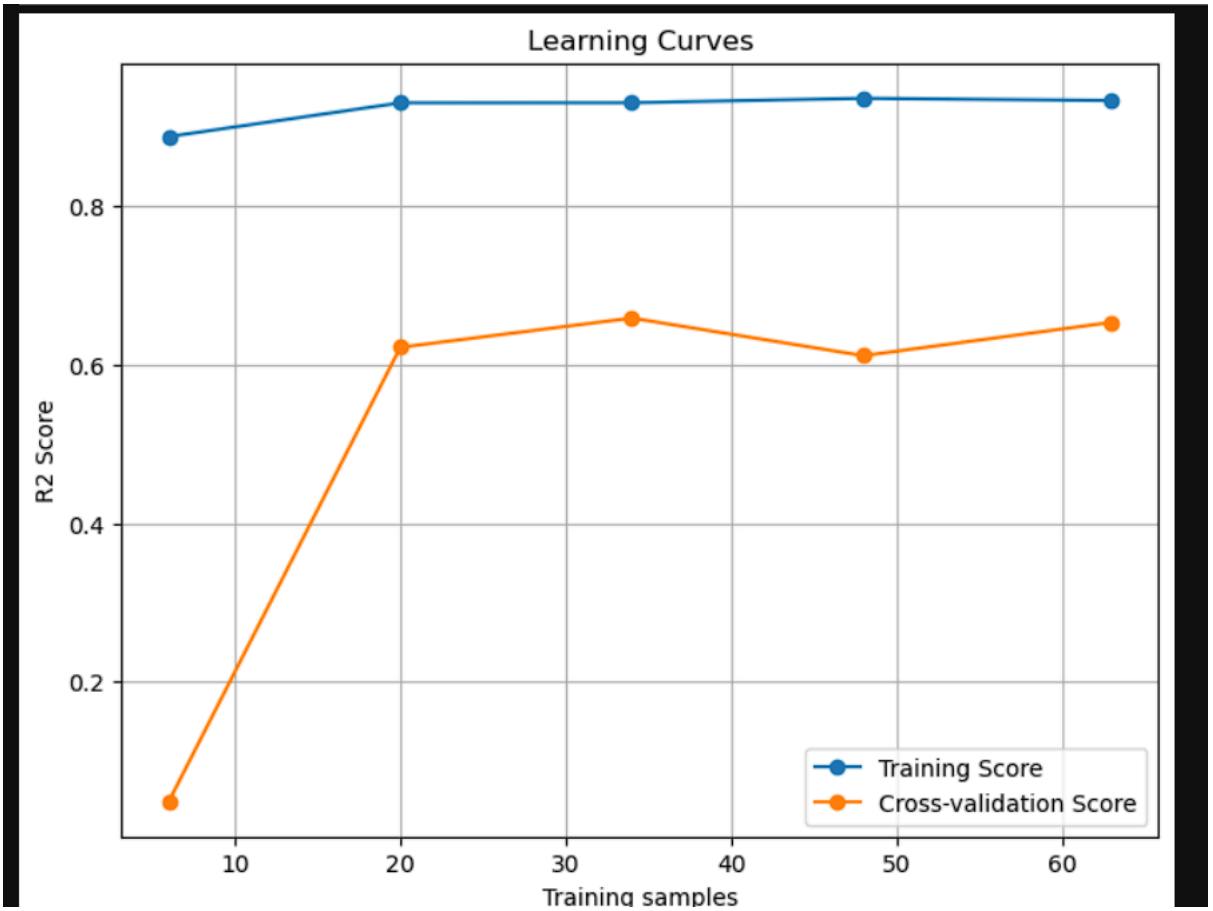

Biểu đồ cho thấy đường Cross-validation score tăng dần và tiến gần đường Training score, chứng tỏ mô hình có khả năng tổng quát hóa tốt. Hiệu suất hiện tại cao ($R^2 > 0.85$), đủ để đưa vào sử dụng. Tuy nhiên, do đường Cross-validation vẫn tiếp tục tăng ở cuối biểu đồ nên mô hình vẫn có thể cải thiện thêm nếu được bổ sung dữ liệu.

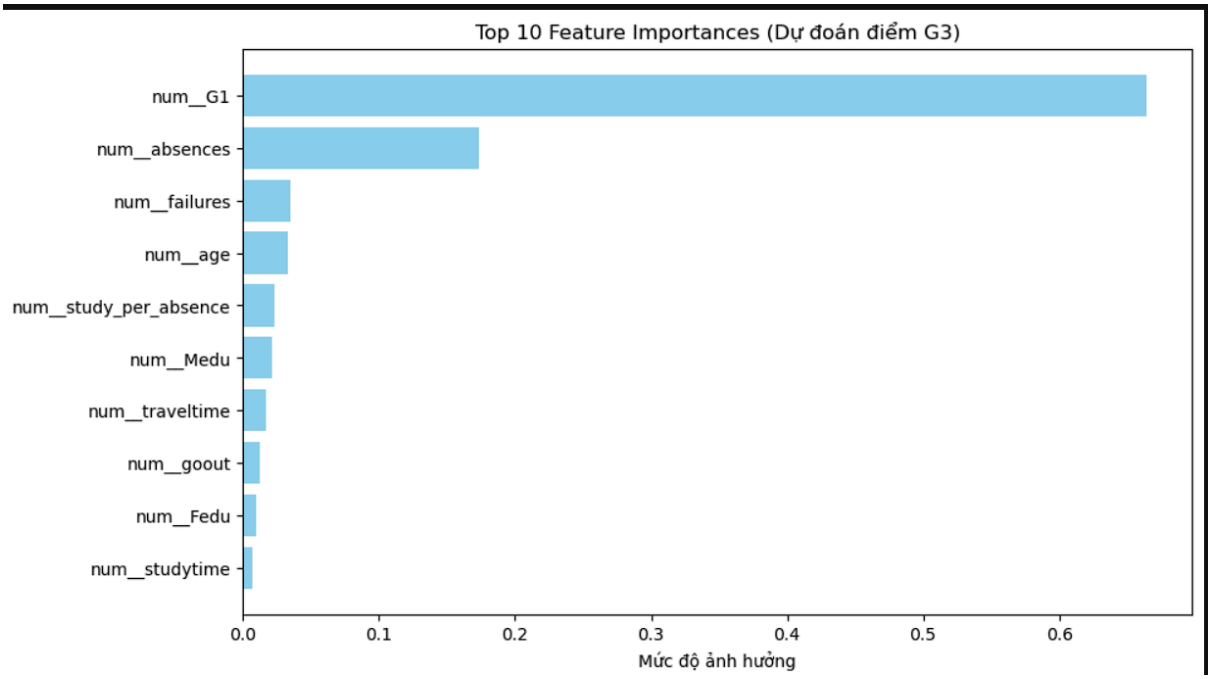

Qua biểu đồ trên, có thể thấy điểm thi kỳ 1 (G1) là đặc trưng quan trọng nhất trong việc dự đoán điểm cuối kỳ, chiếm hơn 60% mức độ ảnh hưởng. Bên cạnh đó, số buổi nghỉ học (absences) và số lần trượt môn (failures) cũng tác động đáng kể đến kết quả. Điều này cho thấy thành tích học tập trước đó và mức độ chuyên cần là các yếu tố quan trọng ảnh hưởng đến điểm số của học sinh

3.3 Model được chọn

Sau khi huấn luyện và đánh giá các mô hình, nhóm lựa chọn Random Forest Regressor là mô hình tốt nhất.
Lý do lựa chọn:
- Có giá trị CV R^2 cao nhất (0.7051), cho thấy khả năng tổng quát hóa tốt.
- Có giá trị Test R^2 cao nhất (0.8292), chứng tỏ mô hình dự đoán chính xác hơn trên tập kiểm tra.
- Có RMSE thấp nhất (1.8716), nghĩa là sai số dự đoán nhỏ hơn.
- Có MAE thấp nhất (1.4216), cho thấy sai số tuyệt đối trung bình thấp nhất.

Kết luận:

Với hiệu suất tốt nhất trên cả tập kiểm tra và Cross-validation, Random Forest Regressor được chọn làm mô hình chính để triển khai trong hệ thống dự đoán điểm số sinh viên.

4. Ứng dụng thực tế

4.1 Use Case Scenario 1

Hệ thống hỗ trợ giáo viên và phụ huynh

Người dùng:
- Giáo viên chủ nhiệm, giáo viên bộ môn hoặc phụ huynh.

Nơi dùng:
- Trường THPT hoặc hệ thống quản lý học sinh.

Đầu vào:
- Điểm kỳ 1 (G1)
- Số buổi nghỉ học (absences)
- Số lần trượt môn (failures)

- Thời gian học tập
- Trình độ học vấn của phụ huynh

Đầu ra:
- Điểm cuối kỳ dự đoán (G3)
- Cảnh báo học sinh có nguy cơ học kém.

4.2 Use Case Scenario 2

Hệ thống tự đánh giá cho học sinh

Người dùng:
- Học sinh THPT.

Nơi dùng:
- Website hoặc ứng dụng học tập.

Đầu vào:
- Thông tin học tập hiện tại.

Đầu ra:
- Điểm dự đoán cuối kỳ.
- Gợi ý cải thiện như tăng thời gian học hoặc giảm nghỉ học.

4.3 Hạn chế khi triển khai

- Dữ liệu huấn luyện còn hạn chế và chỉ phản ánh một nhóm học sinh nhất định.
- Mô hình có thể không chính xác khi áp dụng cho trường hoặc khu vực khác.
- Cần đảm bảo quyền riêng tư của học sinh.
- Không nên sử dụng kết quả dự đoán để đánh giá hoặc phân loại học sinh một cách cứng nhắc.

4.4 Demo

Hệ thống được xây dựng theo kiến trúc:
ReactJS (Frontend)
↓
FastAPI (Backend)

↓
Random Forest Model (.joblib)

Mô tả hoạt động:
- Người dùng nhập dữ liệu học tập vào giao diện.
- Frontend gửi dữ liệu đến API.
- Backend xử lý và sử dụng mô hình AI để dự đoán điểm cuối kỳ.
- Kết quả hiển thị trên giao diện web.

5. Kết luận

5.1 Tóm tắt

Trong dự án này, nhóm đã xây dựng hệ thống dự đoán điểm cuối kỳ của học sinh THPT dựa trên các đặc trưng học tập và cá nhân.
Nhóm đã thực hiện các bước tiền xử lý dữ liệu, tạo thêm đặc trưng mới, huấn luyện và so sánh nhiều mô hình hồi quy như Linear Regression, Gradient Boosting và Random Forest.

Kết quả thực nghiệm cho thấy Random Forest Regressor đạt hiệu suất tốt nhất với:

- CV $R^2 = 0.7051$
- Test $R^2 = 0.8292$
- RMSE = 1.8716
- MAE = 1.4216

Do đó, mô hình này được chọn để triển khai trong hệ thống thực tế.

5.2 Hạn chế

- Tập dữ liệu còn nhỏ và chưa đa dạng.
- Dữ liệu chỉ phản ánh một nhóm học sinh trong một bối cảnh nhất định.
- Một số yếu tố quan trọng như tâm lý, điều kiện kinh tế hoặc phương pháp giảng dạy chưa được đưa vào mô hình.
- Mô hình vẫn có thể cải thiện thêm nếu có nhiều dữ liệu hơn.

5.3 Hướng phát triển

- Thu thập thêm dữ liệu từ nhiều trường hoặc khu vực khác nhau.
- Thử nghiệm thêm các mô hình mạnh hơn như XGBoost hoặc Neural Network.

- Tối ưu hyperparameter để tăng độ chính xác.
- Triển khai hệ thống thực tế trên web hoặc cloud để hỗ trợ giáo viên, phụ huynh và học sinh.